データの分析と処理
科学研究に必要な統計学

青森大学ソフトウェア情報学部
角田均

科学研究と統計学

実験データと統計処理

統計とは

- 「統計」 ＝ データを整理して分析する

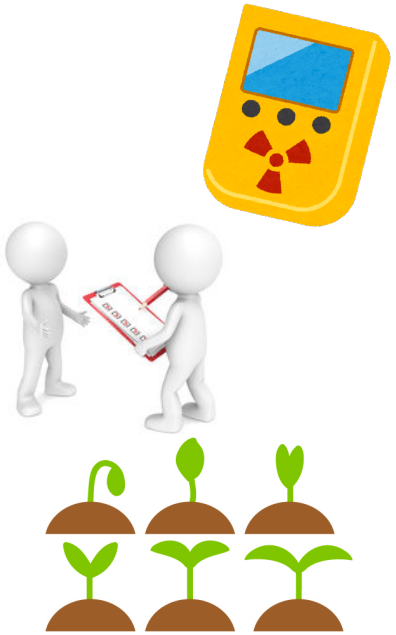

測定や調査で
データを集める

表やグラフに
整理・まとめ

分析、検証、予測

統計学の分類

- 記述統計学
  - グラフや表で大量の事象（データ）を記述する
- 数理統計学
  - 推測統計学
    - 少ないサンプルから全体を予測する
  - 多変量解析
    - 複雑に絡み合った要因を分解、因果関係を明らかにする

人口ピラミッド

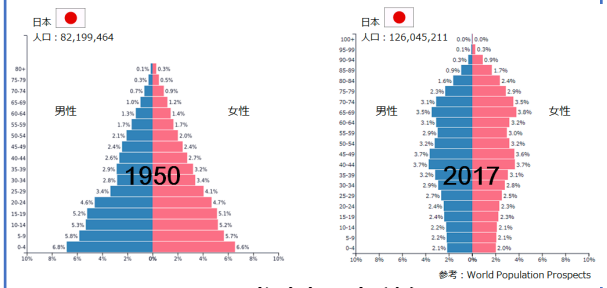

記述統計学

アンケート調査

推測統計学

水?　肥料?　温度?

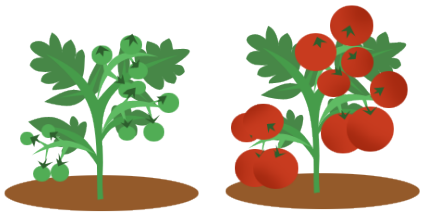

多変量解析

統計学の３つの源流

Adolphe Quetelet
(1796-1874)

近代統計学の祖

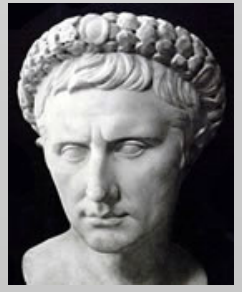

Augustus
(BC63-14)

William Petty
(1632-87)

国の実態をとらえる

Edmond Halley
(1656-1742)

大量の事象をとらえる

Blaise Pascal
(1623-62)

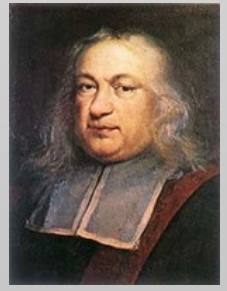

Pierre de Fermat
(16??-1665)

確率的な事象をとらえる

統計学の過去、現在、未来

- 統計学は難しい？
  - 学校で習わない
  - 処理、計算が大変
- 統計学は最強？
  - コンピュータの普及で変わった世界
  - ビジネスの世界に浸透
- これからの統計学
  - 「ビッグデータ」で変わる統計学
  - 「データサイエンス」「機械学習」「人工知能」

データの整理と俯瞰

個票とヒストグラム

データを整理する

- 「個票」を作る

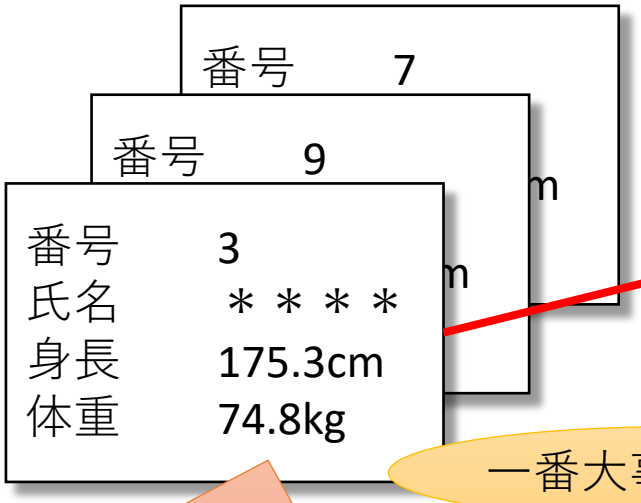

生データ
（未加工データ）

一番大事なデータ

個票
（一次データ）

番号	身長(cm)	体重(kg)
1	169.6	63.3
2	172.2	62.8
3	175.3	74.8
4	181.8	
5	1	
6	168.9	
7	183.5	69.7
8	169.9	59.0
9	158.6	46.1
10	164.2	70.3

個体（レコード）
… 1組のデータ

「変量」

データを整理・集計

データ全体を視覚化する

- 度数分布表とヒストグラム

クラス1の得点分布

番号	得点
A	2
B	5
C	2
D	3
E	4
F	1
G	3
H	3
I	4
J	3

得点データ

平均値はどちらも3.0

クラス2の得点分布

番号	得点
A	1
B	1
C	4
D	5
E	5
F	3
G	5
H	1
I	4
J	1

度数分布表

得点区間	人数
1	1
2	
3	
4	
5	

得点区間	人数
1	
2	
3	
4	
5	

ヒストグラム

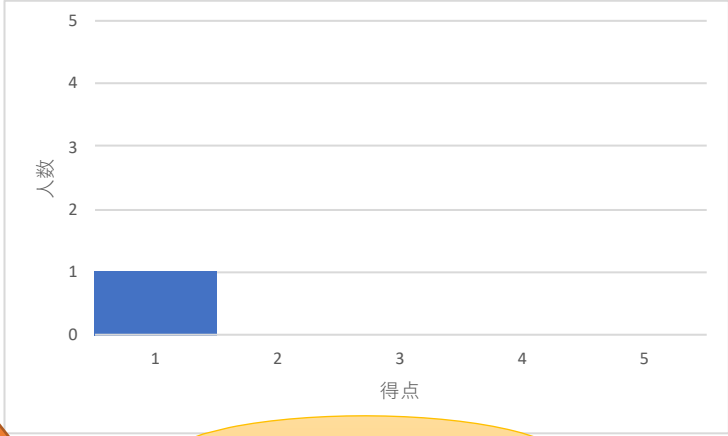

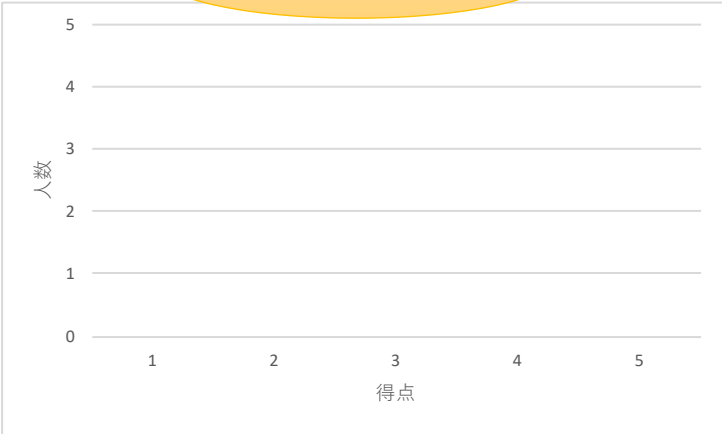

データの代表値

平均値

データの代表値

- 主な代表値
  - 平均値
  - 中央値（メジアン）
  - 最頻値（モード）
  - 最大値・最小値
  - レンジ

データ全体の性質を示す

平均値

- データを平らに均(なら)した値

$$\bar{x} = \frac{x_1 + x_2 + x_3 + \cdots + x_n}{n}$$ （平均値の公式）

例）5人分のテストの成績

番号	得点
A	7
B	5
C	3
D	9
E	6

$$\frac{7+5+3+9+6}{5} = \frac{30}{5} = 6$$

平均値は最も重要な代表値

大数の法則

- サンプルの平均値は、サンプル数を増やすと真の平均値に近づく

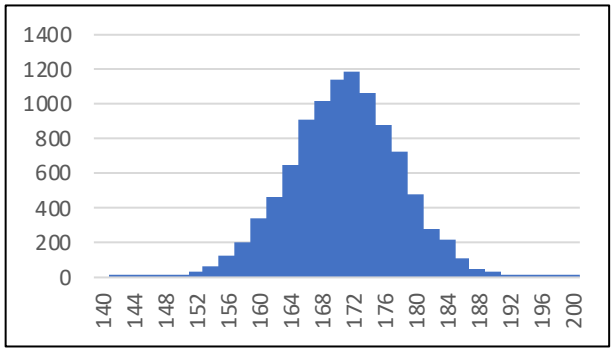

（母集団10000個）平均170.0

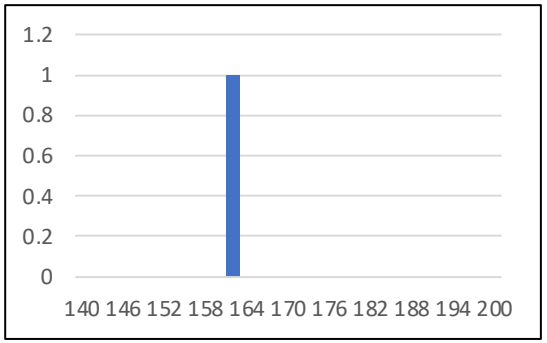

（サンプル1個）平均162.6

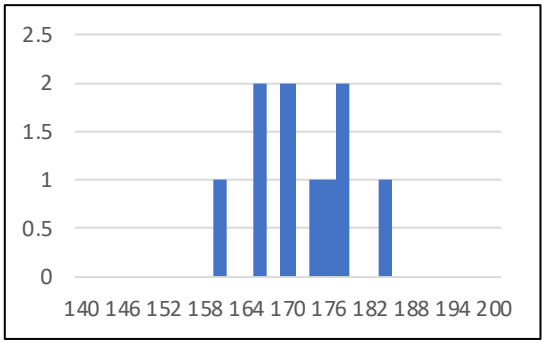

（サンプル10個）平均171.4

…

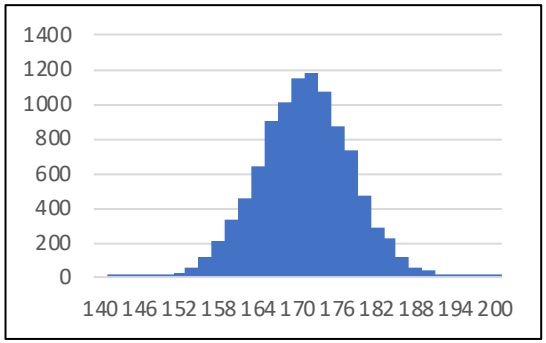

（サンプル10000個）平均170.0

中心極限定理

- 元がどんな分布のデータでも、サンプルの平均値は母集団の平均値の周辺に正規分布する

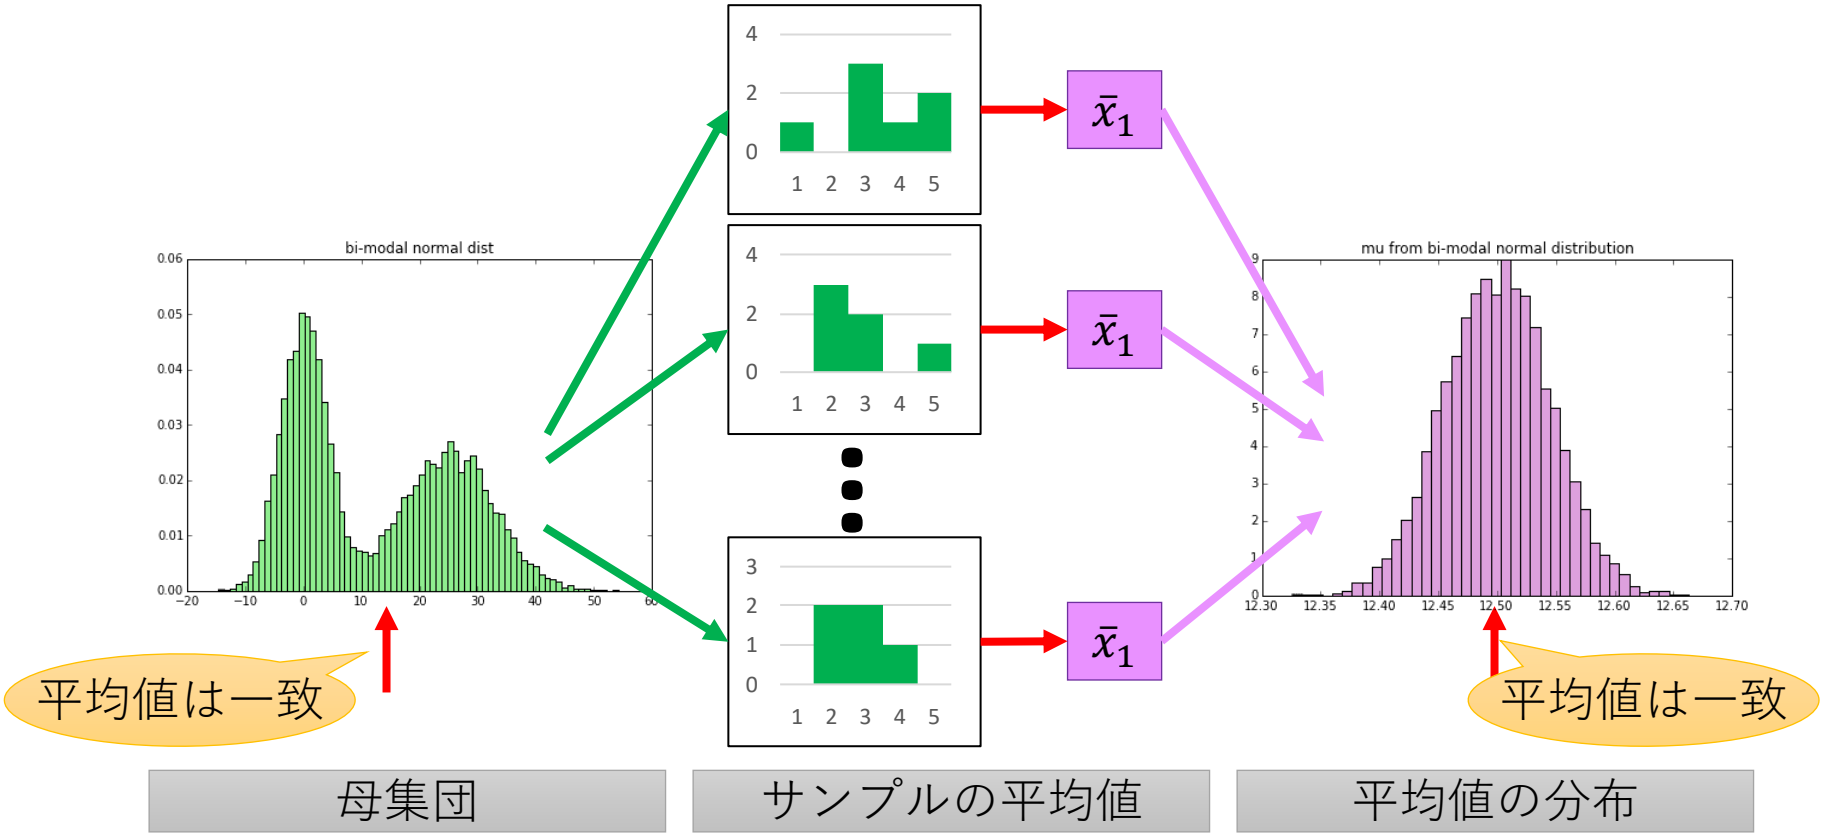

正規分布

- 定義

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

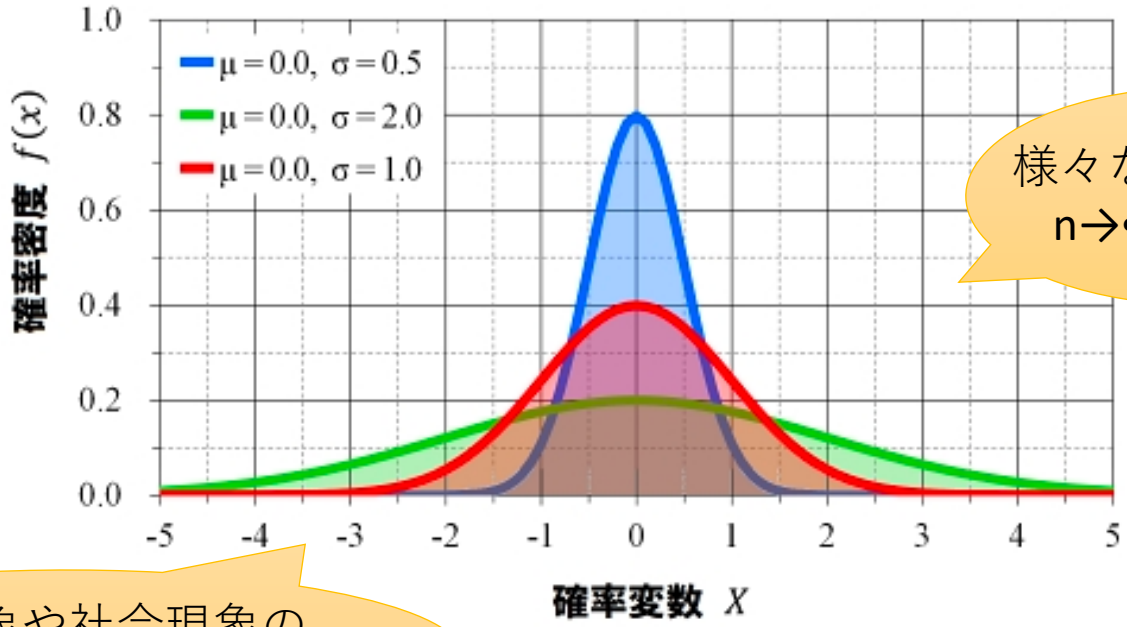

様々な分布関数の
n→∞の極限値

自然現象や社会現象の
多くがこの分布で説明できる

実際にやってみる

指数分布	カイ２乗分布	双峰正規分布

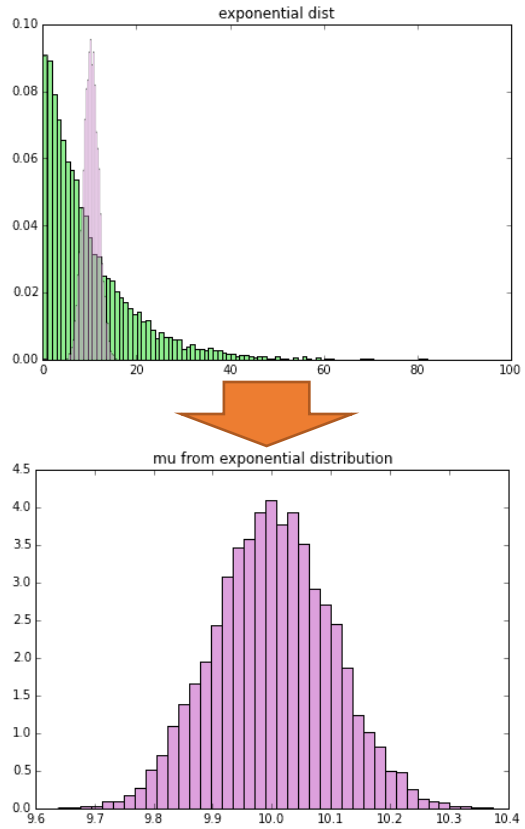

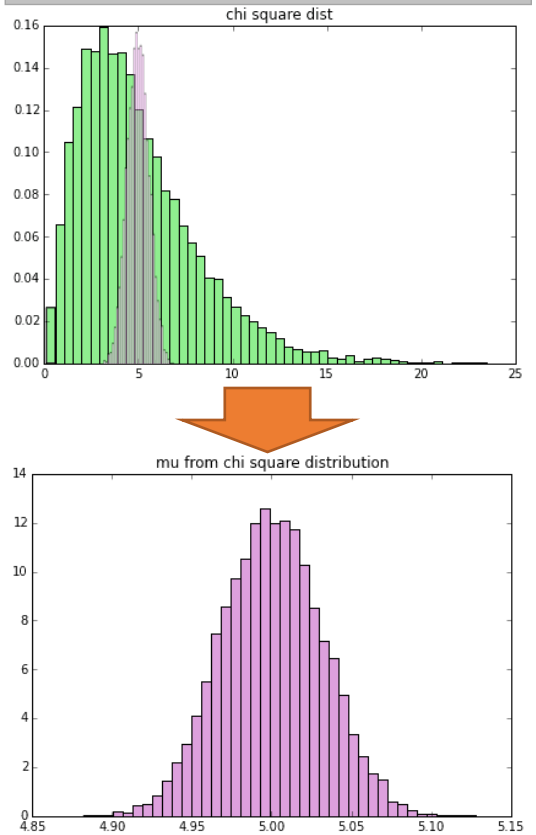

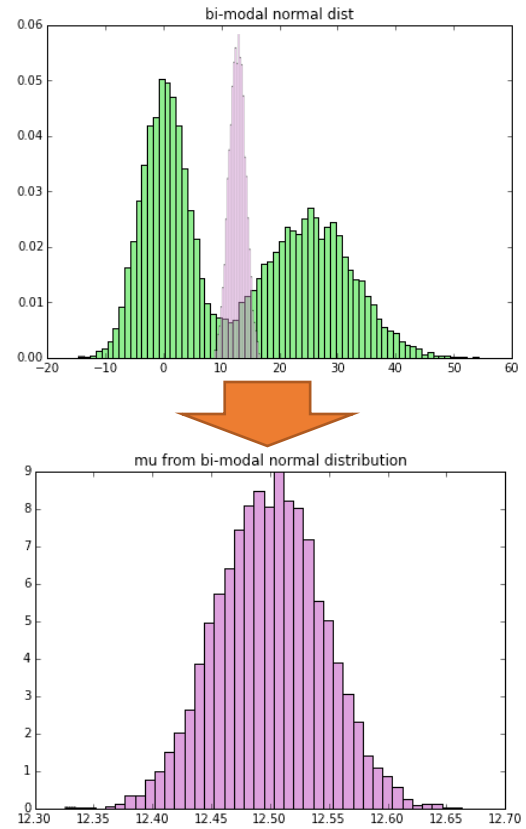

(参考) http://qiita.com/kenmatsu4/items/351284ef430bcfd2c8ed

中央値（メジアン）

- 中央値 = 変量の真ん中の値

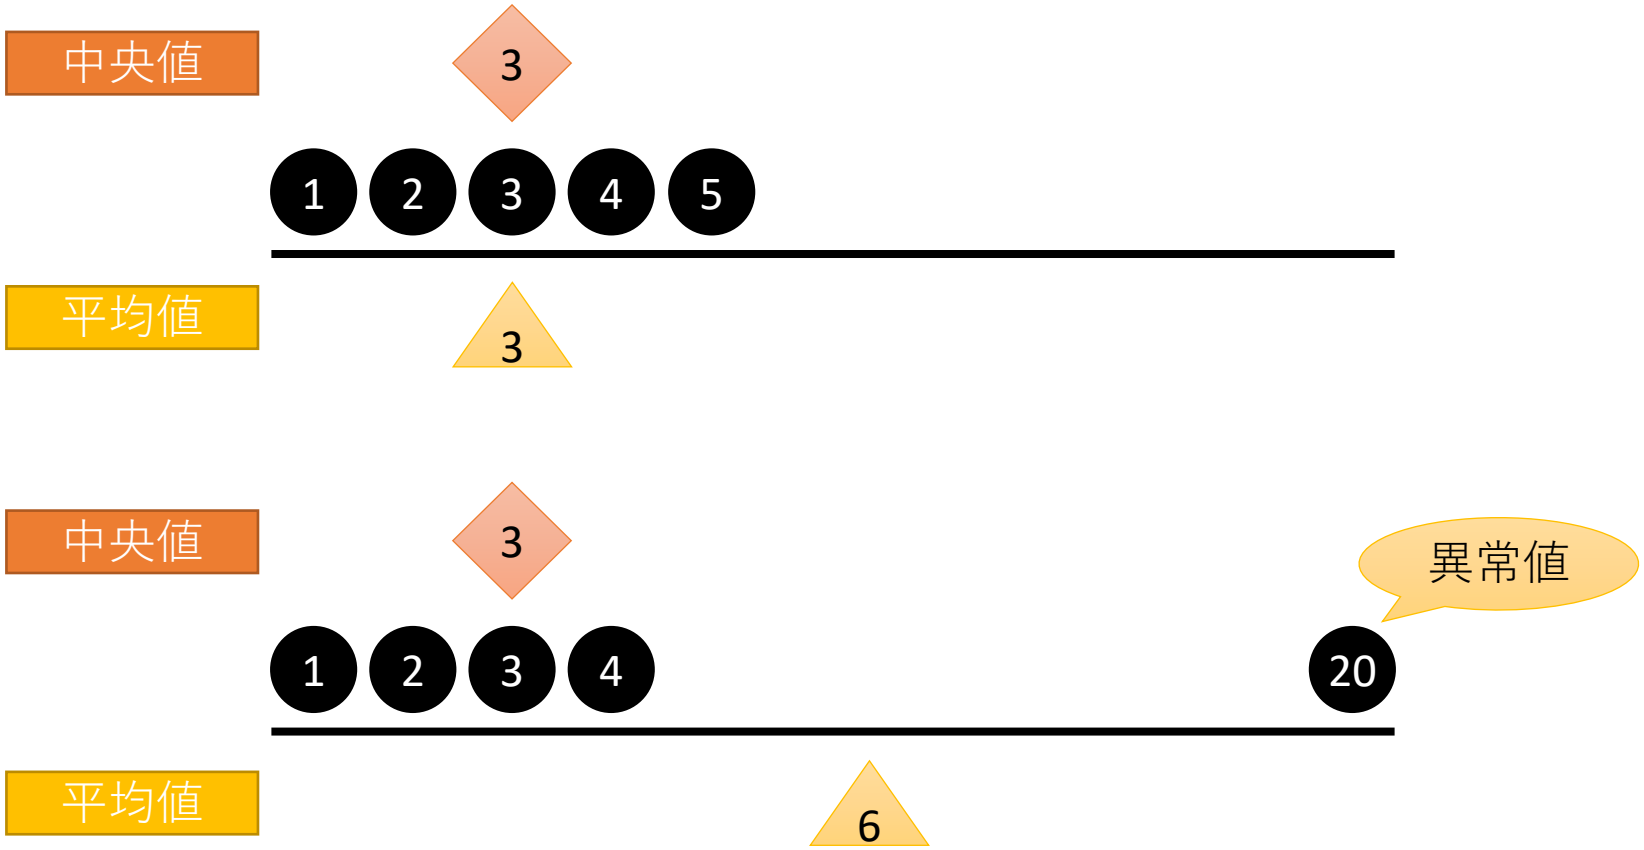

中央値は異常値に強い

最頻値（モード）

- 最頻値 = 最も頻繁に現れる値

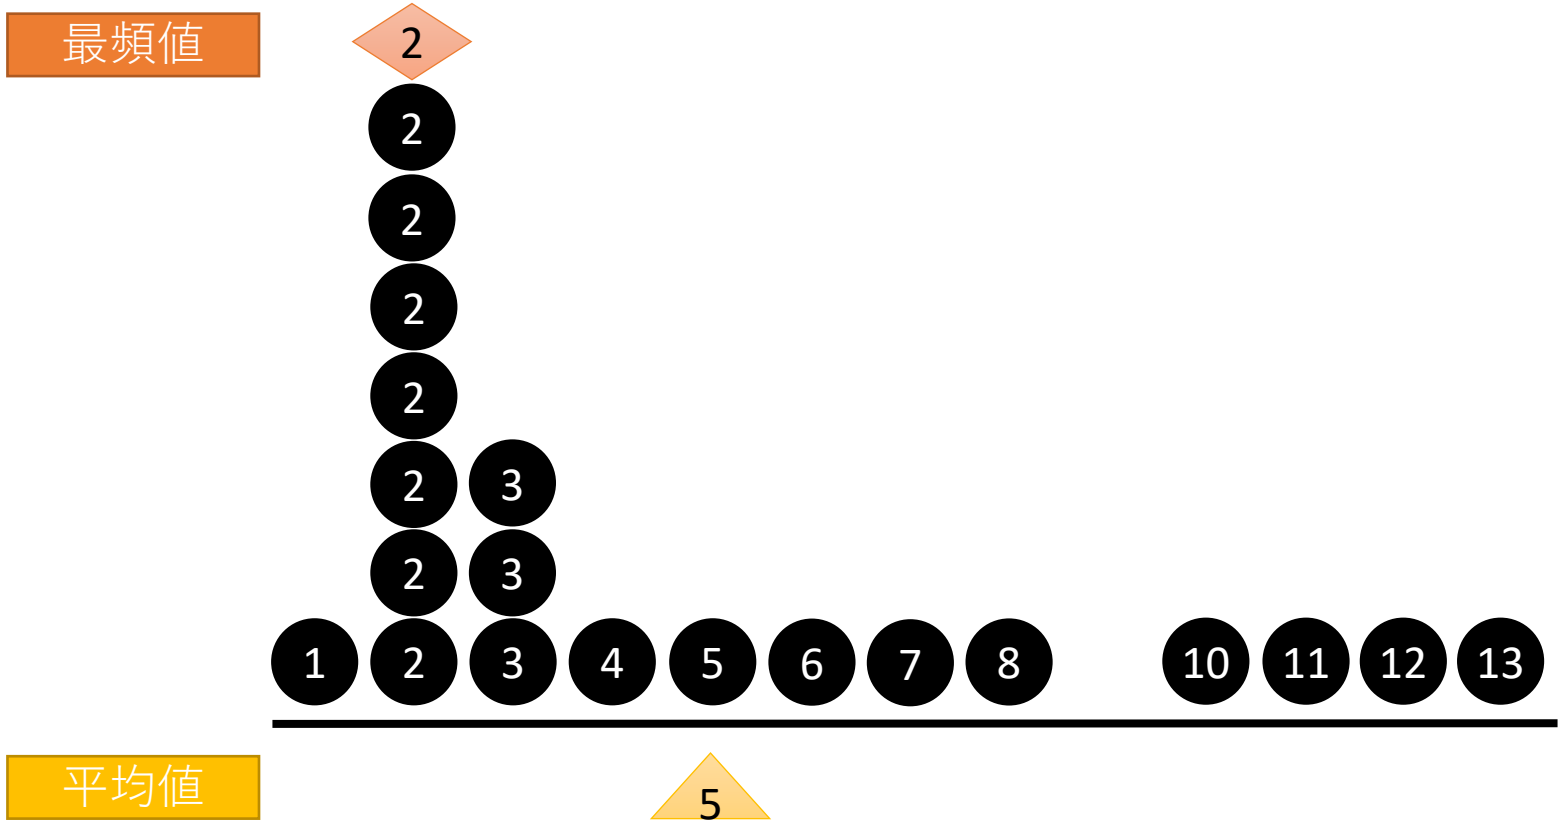

一致するデータの数が一番多い

どれが「代表値」？

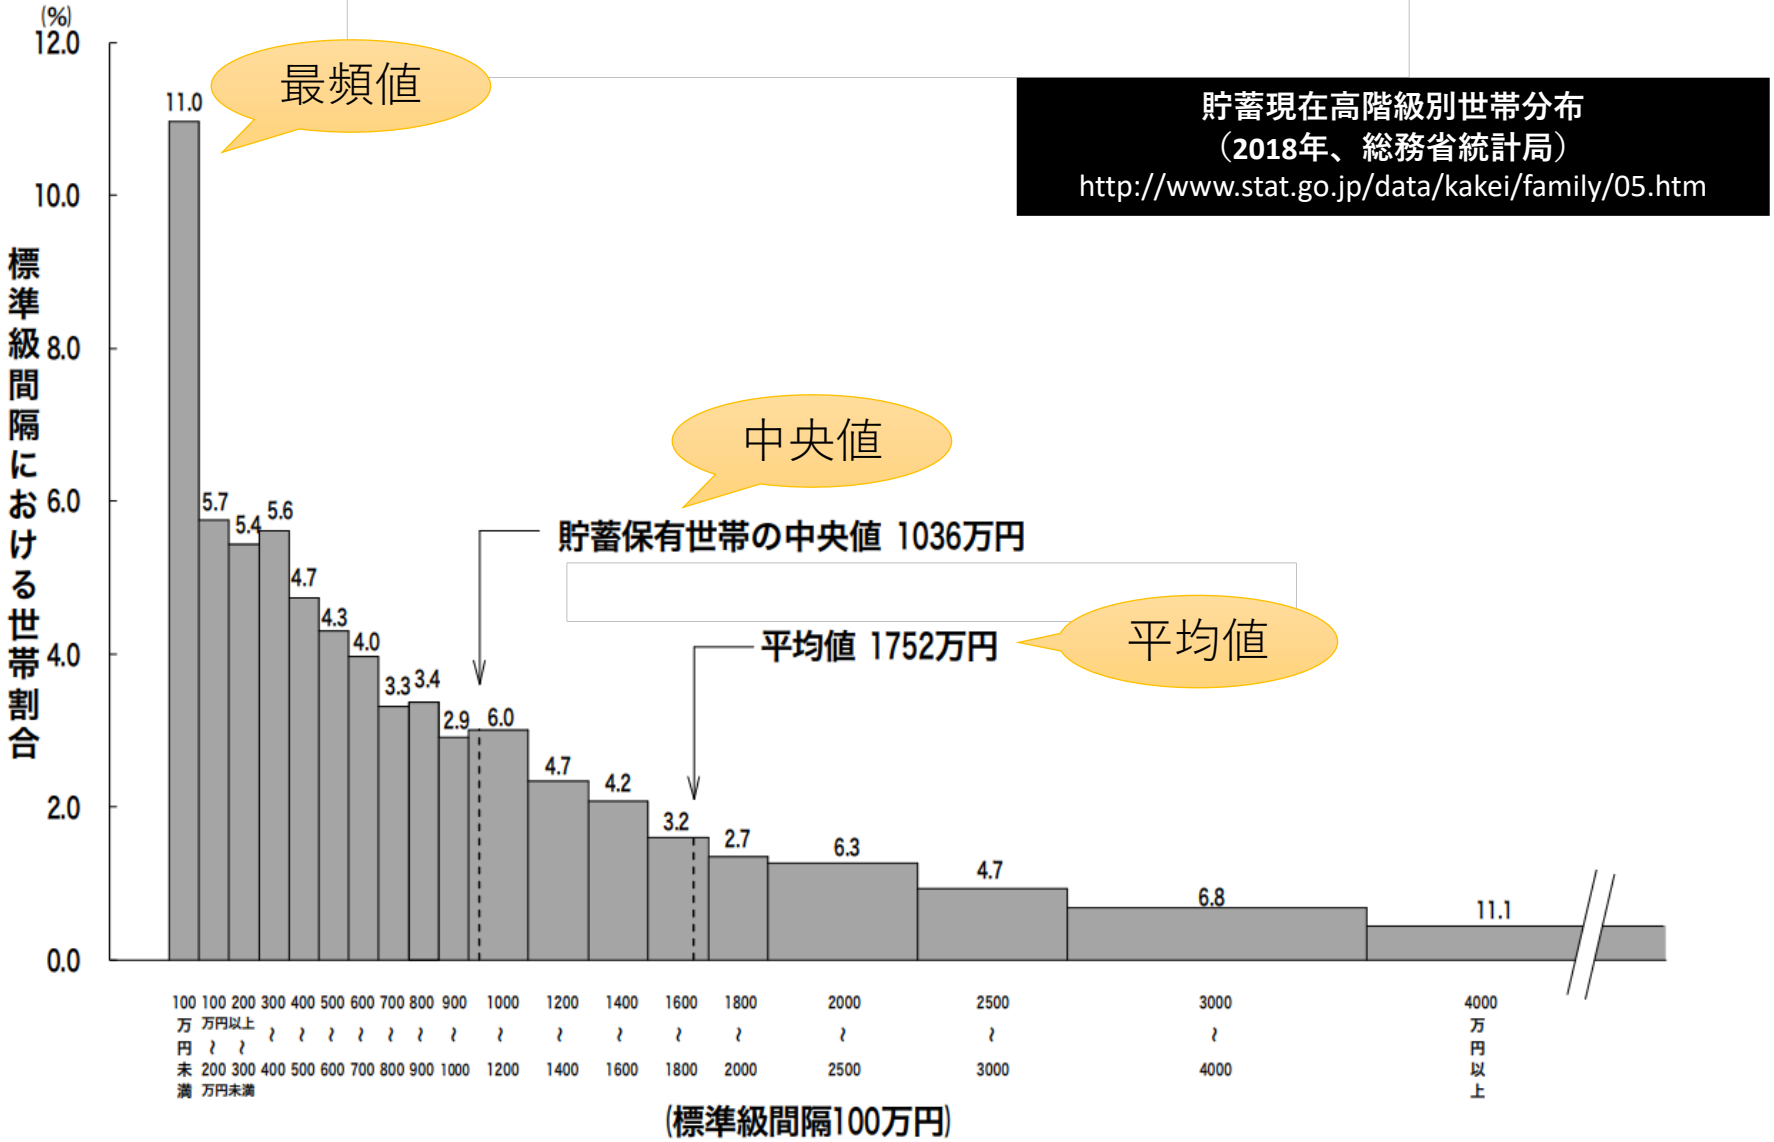
貯蓄現在高階級別世帯分布
（2018年、総務省統計局）
http://www.stat.go.jp/data/kakei/family/05.htm
最頻値
中央値
平均値
貯蓄保有世帯の中央値 1036万円
平均値 1752万円
(%)
12.0
10.0
8.0
6.0
4.0
2.0
0.0
標準級間隔における世帯割合
11.0
5.7
5.4
5.6
4.7
4.3
4.0
3.3
3.4
2.9
6.0
4.7
4.2
3.2
2.7
6.3
4.7
6.8
11.1
100万円未満
100万円以上～200万円未満
200～300
300～400
400～500
500～600
600～700
700～800
800～900
900～1000
1000～1200
1200～1400
1400～1600
1600～1800
1800～2000
2000～2500
2500～3000
3000～4000
4000万円以上
(標準級間隔100万円)

データのばらつき

標準偏差

ばらつき度合いの表現

- 同じ平均値でも、ばらつきの違うデータ

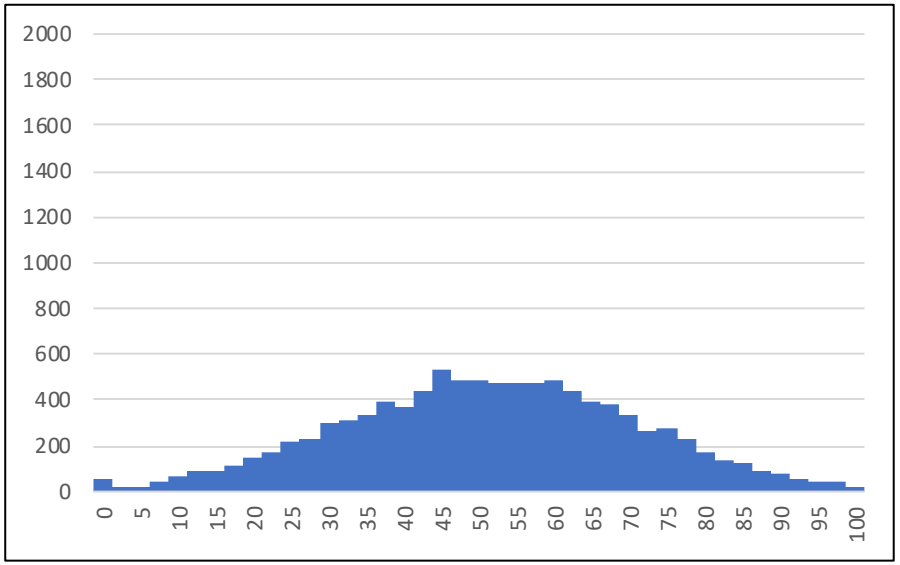

データ数10000、平均値50.0

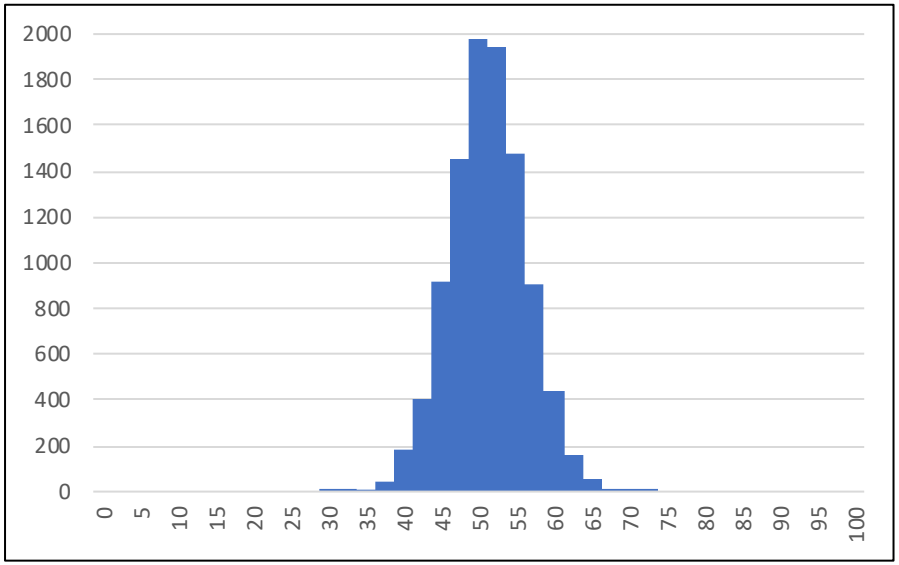

データ数10000、平均値50.0

ばらつき度合いを表す指標

- 「偏差」 … 平均値との差

$$偏差 = x - \bar{x}$$

- 「分散」 … 偏差の2乗の平均

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \ \dots + (x_n - \bar{x})^2}{n}$$

- 「標準偏差」 … 分散の平方根

$$\sigma = \sqrt{\sigma^2}$$

偏差

個別のデータごとの指標

- 偏差 … 平均値との差

偏差$= x - \bar{x}$

ばらつきが大きい = 平均から離れたデータが多い

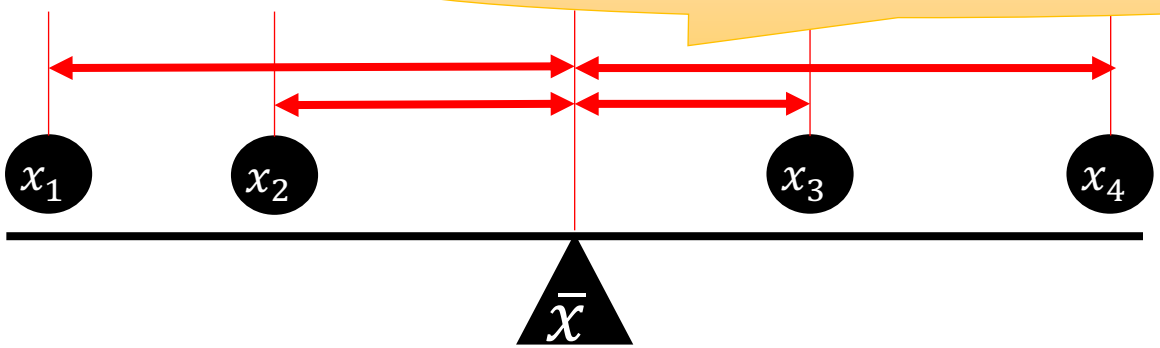

ばらつきが小さい = 平均に近いデータが多い

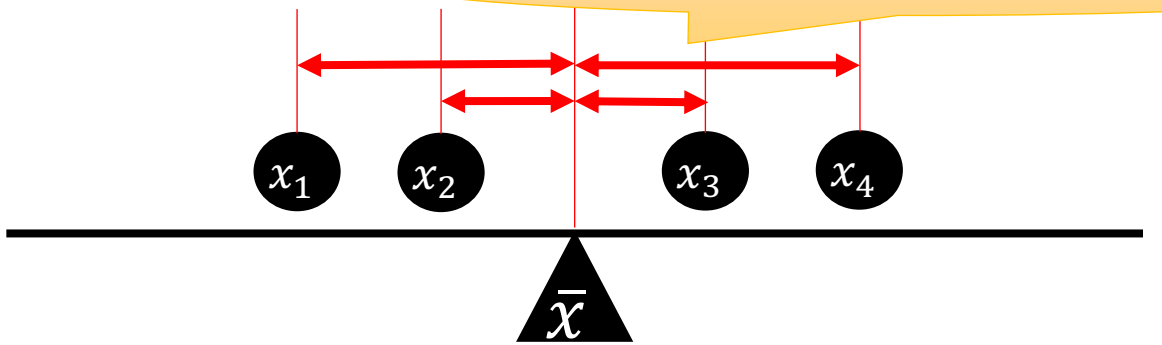

分散

データ全体の指標

- 分散 … 偏差の2乗の平均

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \ldots + (x_n - \bar{x})^2}{n}$$

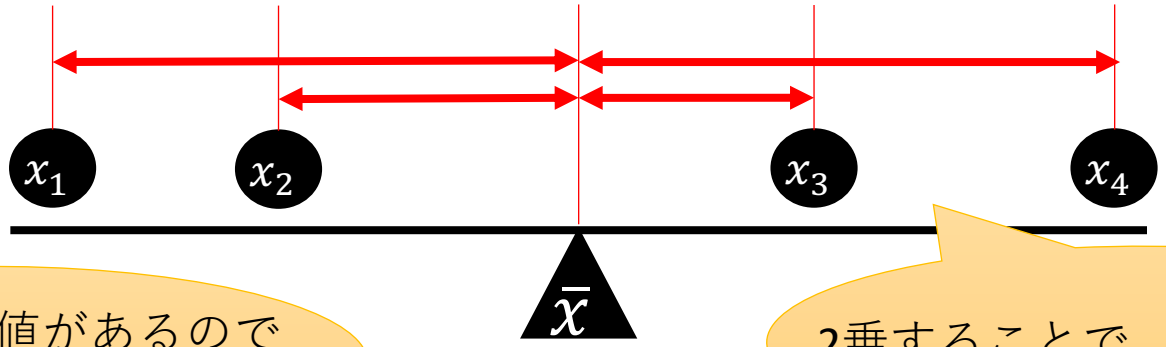

偏差は正負の値があるので
偏差のまま合計すると0になる

2乗することで、差を強調する

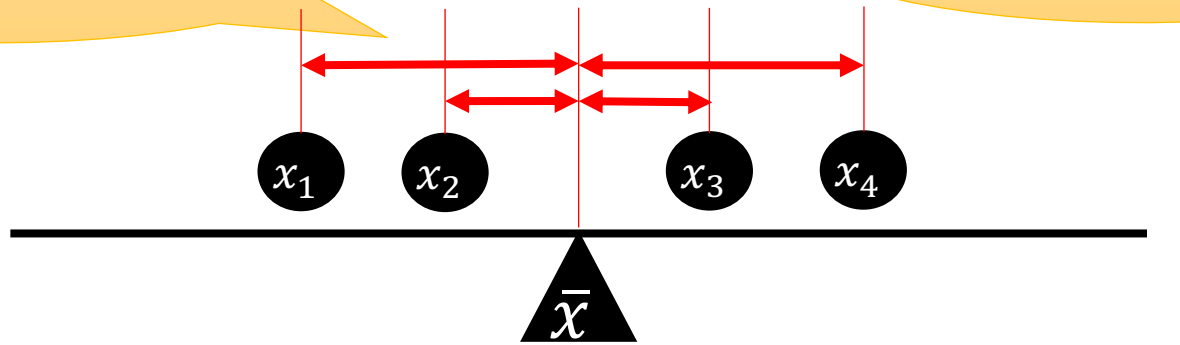

標準偏差

- 標準偏差 … 分散の平方根

$$\sigma = \sqrt{\sigma^2}$$

偏差$= x - \bar{x}$

元のデータと同じ単位

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \ldots + (x_n - \bar{x})^2}{n}$$

元のデータの単位の2乗

$$\sigma = \sqrt{\sigma^2}$$

元のデータと同じ単位

標準偏差は元のデータと直接比較できる

標準偏差の意味

（例）7人分のテスト

番号	得点	偏差	偏差の2乗
A	9		
B	4		
C	10		
D	5		
E	8		
F	7		
G	6		

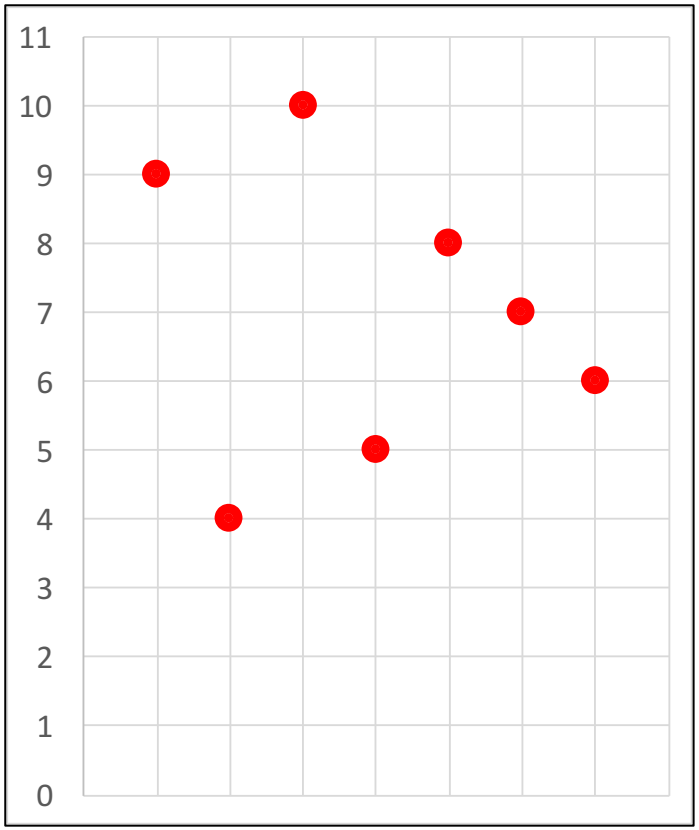

正規分布と標準偏差

- 平均値の周りにデータが含まれる確率

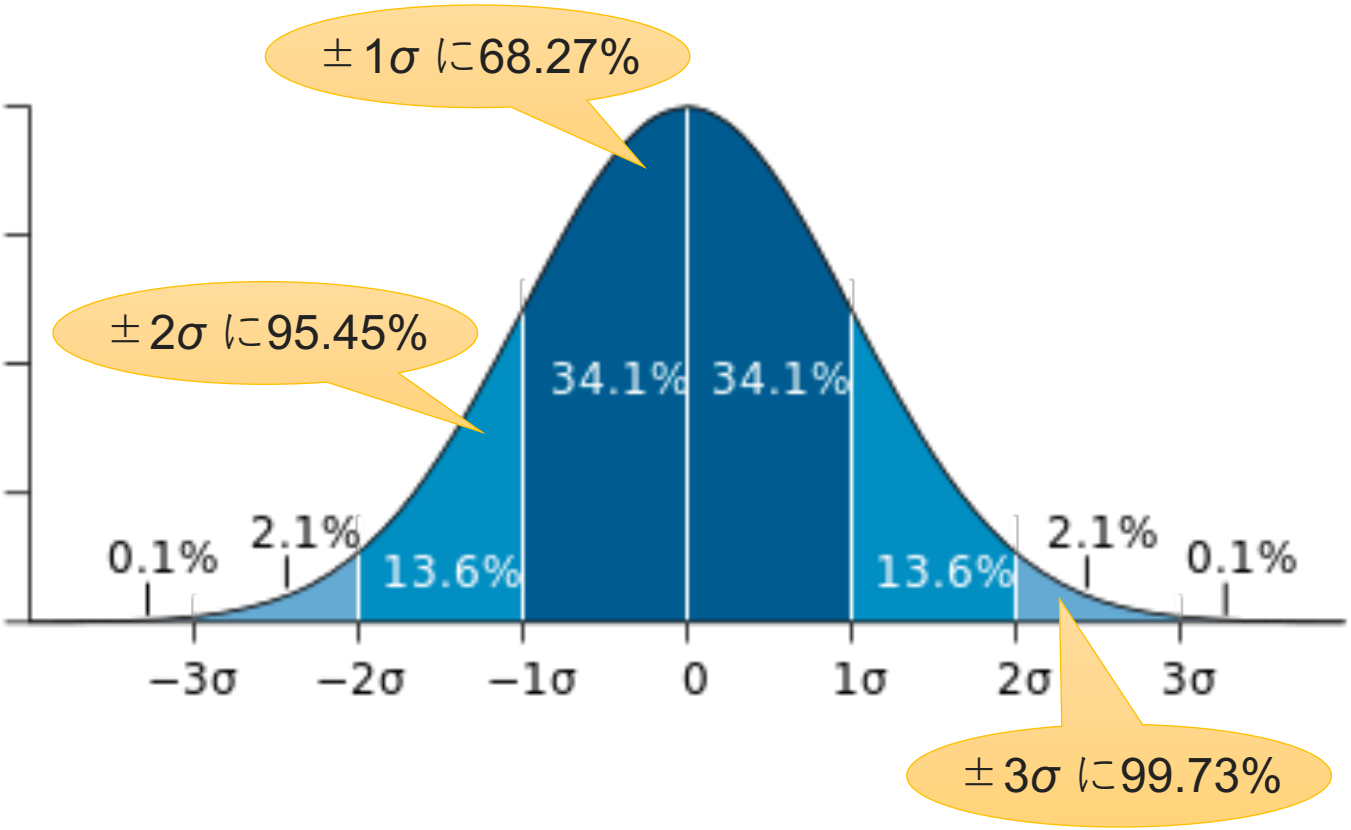

標準誤差

- 標準誤差 … 推定値（平均値）の標準偏差

$$\text{標準誤差} = \frac{\sigma}{\sqrt{n}}$$

<u>2種類の測定データ</u>

①多くのバラついた値を測定する場合
　集団全体の特性を記述・分析する
　例）40人のクラスのボール投げの距離を集計した

平均値 + 標準偏差

②唯一の正しい値を測定する場合
　誤差を含む測定から、正しい値を推定する
　例）学校から自宅までの距離を10回測った

平均値 + 標準誤差

標準誤差の意味

（例）10回の測定値と平均値と標準誤差

Aの測定			
10.57	7.82	11.09	12.49
9.72	12.26	10.19	12.91
10.87	8.41	8.62	11.18
9.45	7.26	9.22	9.74
7.11	9.49	10.47	8.66
10.16	11.00	9.68	13.25
7.55	6.40	7.60	9.36
14.00	11.88	7.59	8.36
12.09	6.50	12.41	13.28
10.88	11.64	11.83	11.91
10.24	9.27	9.87	11.11

Bの測定			
10.27	10.32	10.28	10.28
10.04	10.25	10.34	10.15
10.18	10.12	10.16	10.40
10.24	10.19	10.22	10.24
10.29	10.25	10.24	10.04
10.25	10.13	10.34	10.40
10.19	10.21	10.04	10.20
10.38	10.27	10.25	10.29
10.27	10.32	10.34	10.27
10.28	10.26	10.24	10.16
10.24	10.23	10.25	10.24

測定の信頼度を上げる

- 標準誤差を小さくするために

測定精度を高める

標準偏差（ばらつき）を小さくする

標準誤差$= \frac{\sigma}{\sqrt{n}}$

測定回数を増やす

100倍の回数で10倍の精度

変量同士の関係

相関係数

散布図

（例）身長と体重を同時にプロット

番号	身長	体重
1	147.9	41.7
2	163.5	60.2
3	159.8	47.0
4	155.1	53.2
5	163.3	48.3
6	158.7	55.2
7	172.0	58.5
8	161.2	49.0
9	153.9	46.7
10	161.6	52.5

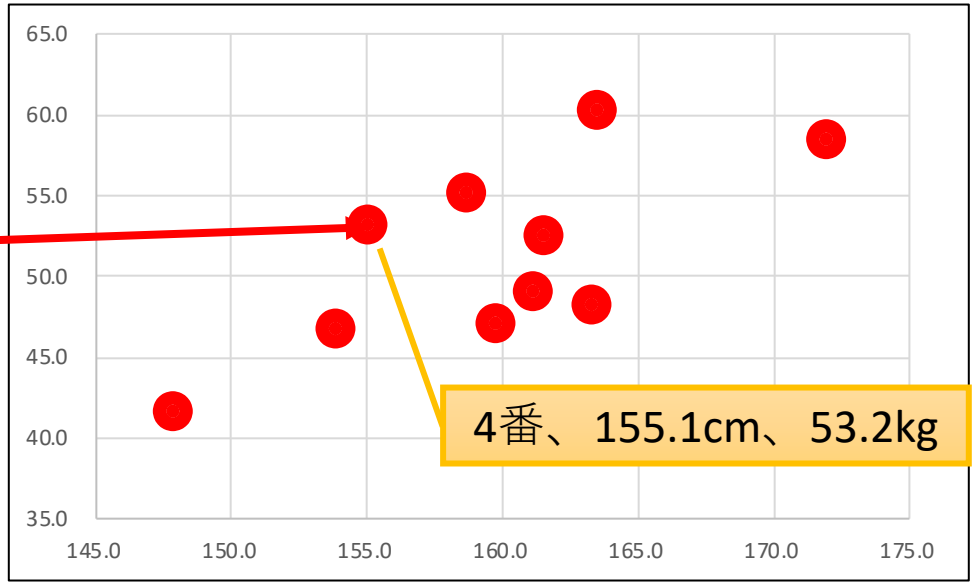

2つの変量による分布

相関

- 変量間の関係

一方の変量の変化に対する
他方の変量の変化の傾向

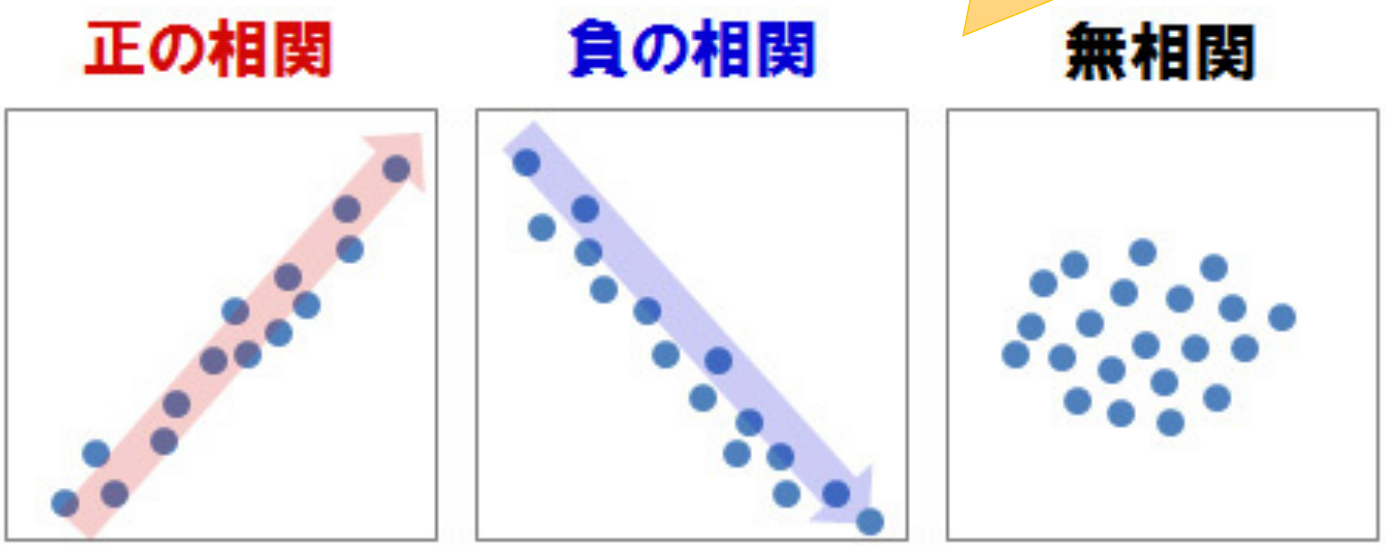

正の相関	負の相関	無相関
一方が増えれば 他方も増える	一方が増えれば 他方が減る	どちらでもない

共分散

- 定義

$$s_{xy} = \frac{(x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + \cdots + (x_n - \bar{x})(y_n - \bar{y})}{n}$$

$s_{xy} > 0$ならば正の相関

$s_{xy} \fallingdotseq 0$ならば無相関

$s_{xy} < 0$ならば負の相関

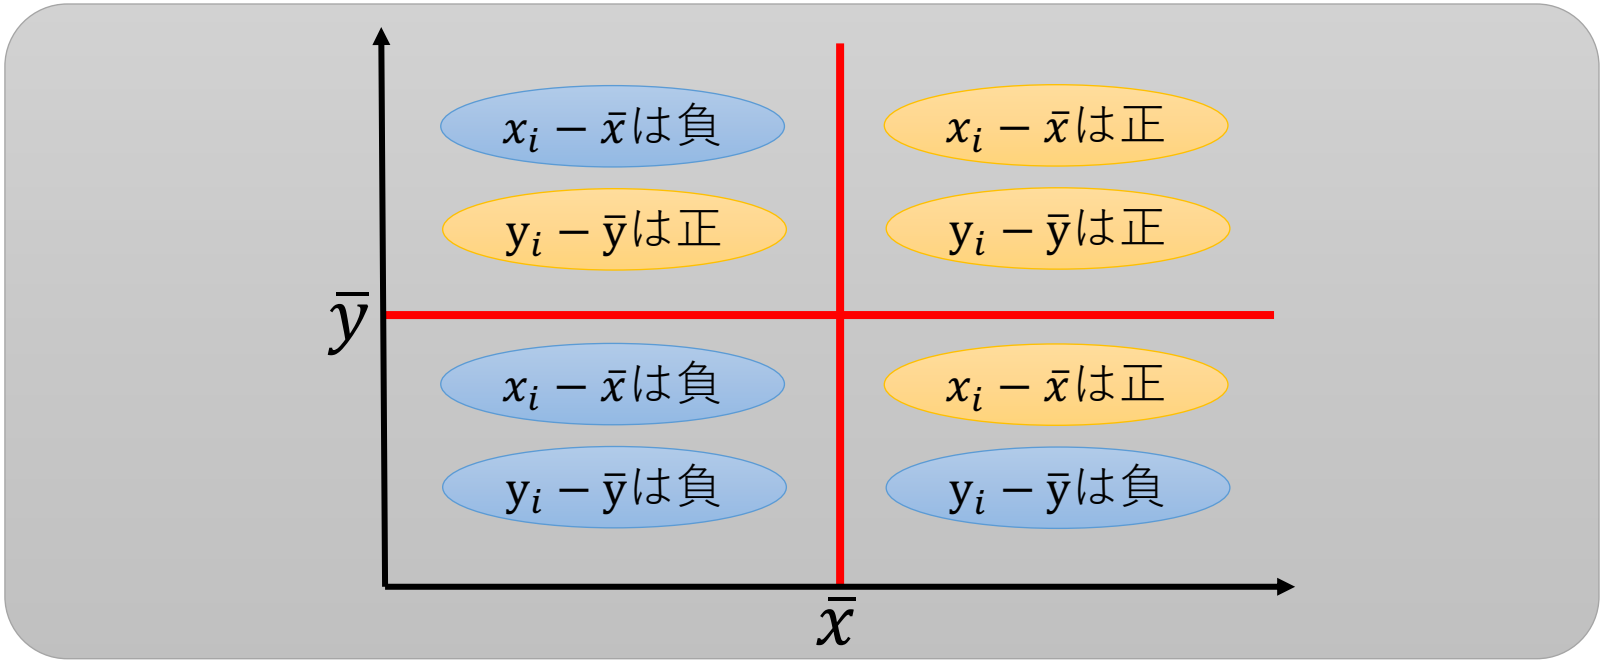

相関係数

- 定義

$$r_{xy} = \frac{s_{xy}}{\sigma_x \sigma_y}$$

相関係数は−1〜1の範囲で
相関の正負と強弱を示す

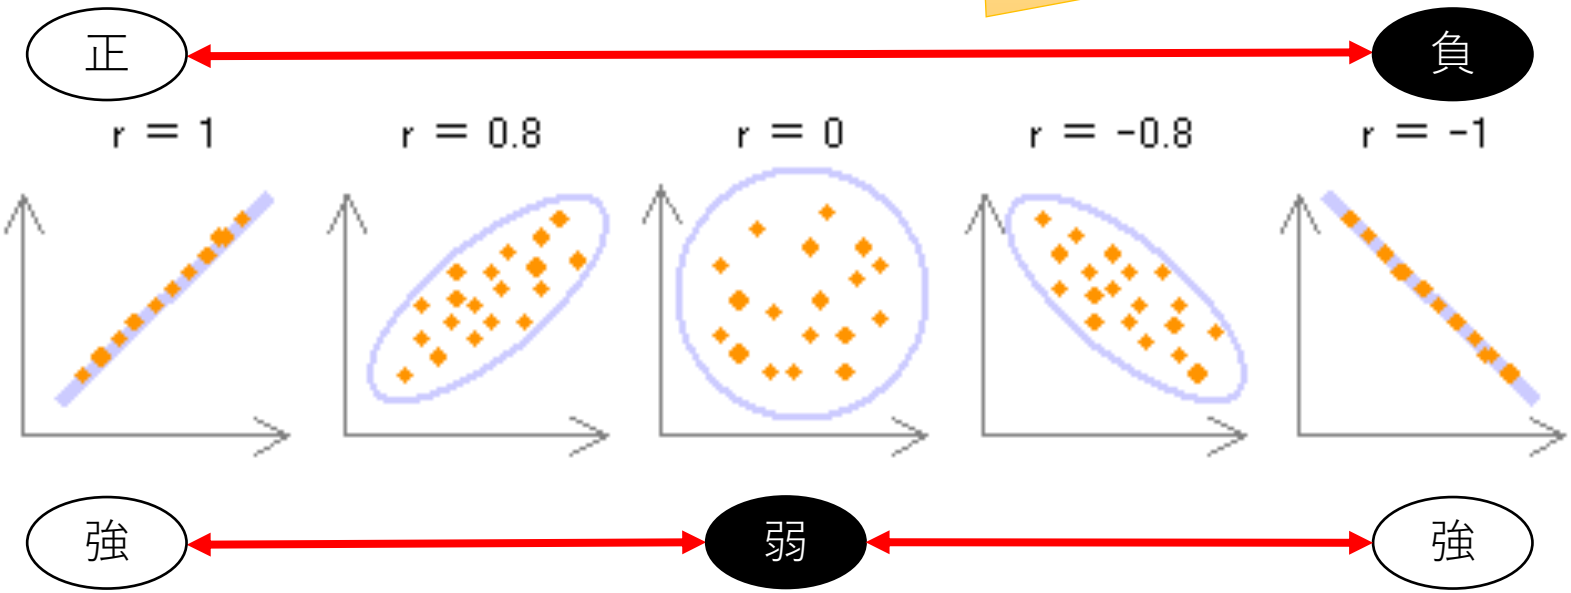

回帰直線

- 多変量解析

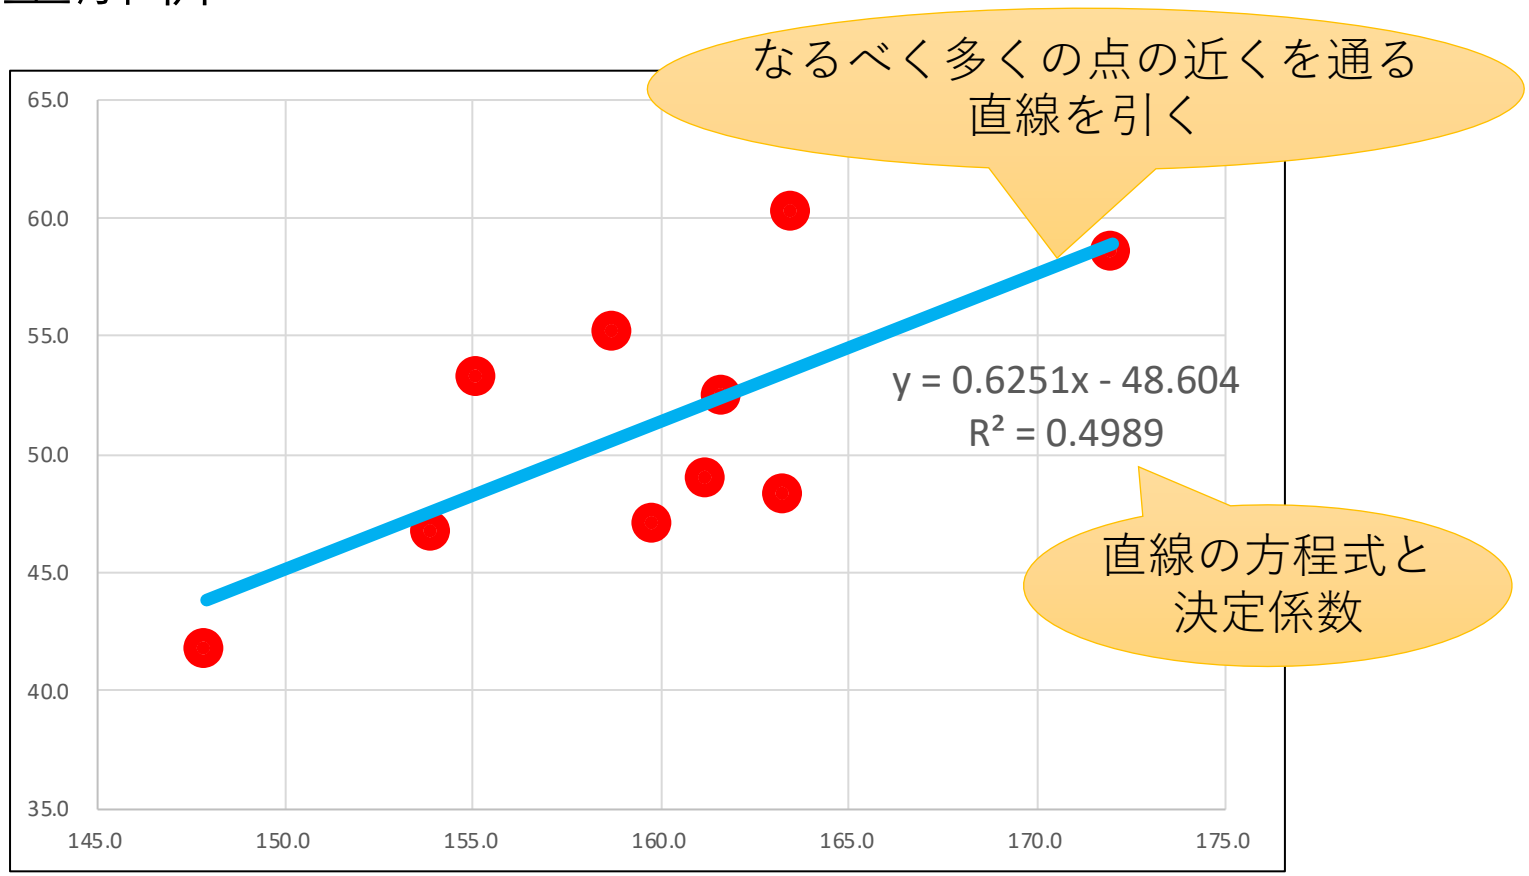
なるべく多くの点の近くを通る
直線を引く
y = 0.6251x - 48.604
R² = 0.4989
直線の方程式と
決定係数
65.0
60.0
55.0
50.0
45.0
40.0
35.0
145.0
150.0
155.0
160.0
165.0
170.0
175.0